T4.3 Protocole HTTP

1. 4.3.1 Le protocole HTTP : des requêtes et des réponses

HTTP (HyperText Transfer Protocol) est le protocole qui régit la communication entre :

- le client (la machine de l'utilisateur qui souhaite obtenir une page web). On dit que le client effectue une **requête**.
- le serveur (la machine sur laquelle sont stockés les fichiers nécessaires à l'affichage de cette page web). Le serveur va renvoyer une **réponse**.

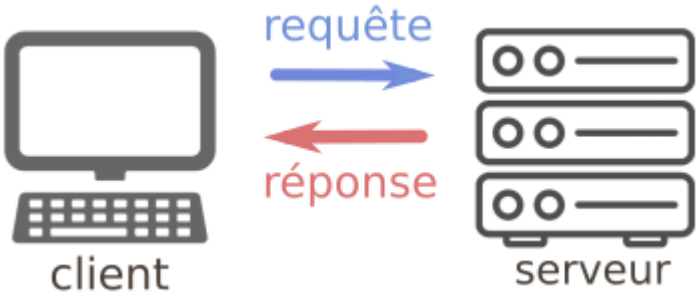

2. 4.3.2 Déroulé d'une requête

Prenons pour exemple la requête d'un navigateur vers la page : http://lyceevalois.com/nsi/bellepage.html

- le navigateur analyse l'url : la demande concerne la page `nsi/bellepage.html`, stockée sur le serveur `lyceevalois.com`.
- une demande est préalablement effectuée auprès pour obtenir l'adresse IP du serveur `lyceevalois.com`. Ici, l'adresse IP sera `2001:41d0:1:1b00:213:186:33:4` (au format Ipv6, on la retrouvera dans la capture de la fenêtre d'Outils de devéloppement).
- la requête est effectuée sur le port 80 de l'adresse `2001:41d0:1:1b00:213:186:33:4`.
- la réponse est envoyée au navigateur, qui en extrait la charge utile et procède à l'affichage de la page.

3. 4.3.3 Analyse d'une requête

Avec un navigateur

Ouvrir le lien précédent avec Firefox, puis ouvrir les «Outils de développement» (clic droit sur la page web puis «Inspecter», ou `Ctrl+Maj+I`). Sélectionner l'onglet «Réseau», puis cliquer sur la première ligne, vous devez obtenir ceci (ou à peu près):

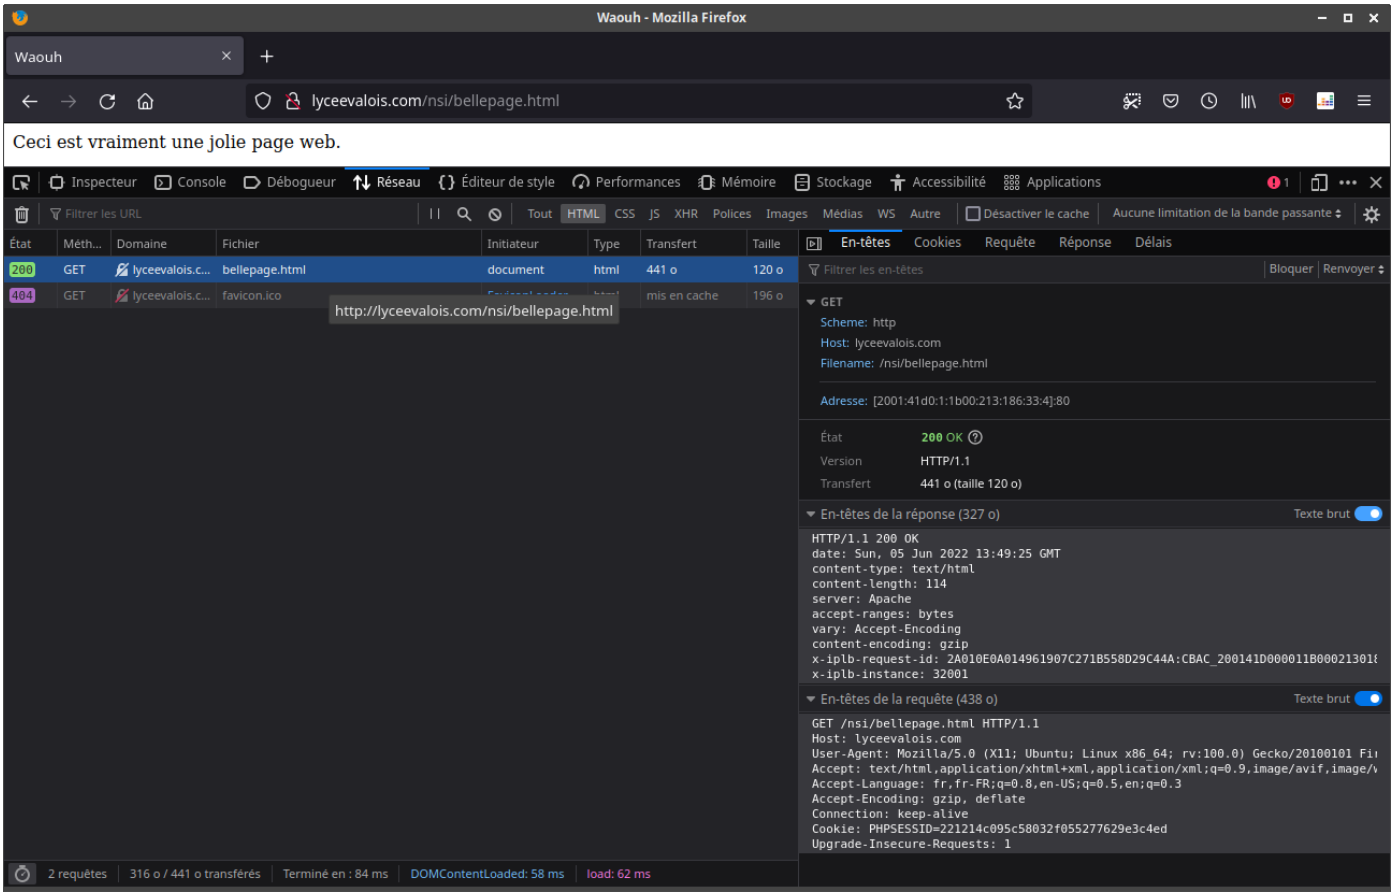

Observons à partir de l'Inspecteur d'élément d'un navigateur (ici Firefox) les informations qui transitent lors de la requête et de la réponse.

URL et méthode GET

La requête de type GET vers l'url `http://lyceevalois.com/nsi/bellepage.html` a généré un code de réponse **200 OK**, ce qui signifie que la requête a été traitée et que la réponse contenant la page a été envoyée.

On peut trouver à l'adresse https://developer.mozilla.org/fr/docs/Web/HTTP/Status la totalité des codes de réponse possibles.

Citons par exemple :

- **304 Not Modified** : la page n'a pas eu besoin d'être renvoyée, elle indique au navigateur d'aller la rechercher dans son cache.
- **403 Forbidden** : le client n'a pas le droit d'accès à la page.
- **404 Not Found** : la page demandée est introuvable
- **500 Internal Server Error** : le serveur a rencontré une erreur qu'il ne sait pas traiter.

Structure de la réponse

En observant la taille totale des données transférées (326 octets), on peut comprendre que la réponse faite par le serveur est constituée :

- d'un **en-tête** (326 octets) qui contient :

Algo

```
HTTP/1.1 200 OK
date: Sun, 05 Jun 2022 15:29:46 GMT
content-type: text/html
content-length: 114
server: Apache
accept-ranges: none
vary: Accept-Encoding
content-encoding: gzip
x-iplb-request-id:
2A010E0A014961907C271B558D29C44A:CDC4_200141D000011B000213018600330004:0050_629C

x-iplb-instance: 31974
```

- du corps de la **réponse** (dont on sait d'après l'en-tête qu'il pèse 114 octets). Ce corps de la réponse est la charge utile de la réponse. Elle contient ici le code html de la page (voir onglet «Réponse»:

HTML

```
<!DOCTYPE html>
<html>
<head>
<title>Waouh</title>
</head>
<body>
Ceci est vraiment une jolie page web.
</body>
</html>
```

Remarque

On peut observer que le navigateur a aussi effectué (de sa propre initiative) une requête vers un fichier `favicon.ico` qui est l'icone de la page web dans les onglets du navigateur ou la barre de favoris. Ce fichier n'a pas été trouvé sur le serveur d'où la réponse **404**.

De manière générale, une requête vers un site web moins élémentaire va occasionner une multitude de réponses (essayer avec le site web de votre choix).

Avec Python

On peut effectuer des requêtes HTTP avec le module `requests` (entre autres). Par exemple:

Script Python

```
import requests
r = requests.get('http://lyceevalois.com/nsi/bellepage.html')
```

On peut récupérer les informations précédentes:

Script Python

```
>>> r
<Response [200]>
>>> r.headers
{'date': 'Sun, 05 Jun 2022 16:26:27 GMT', 'content-type': 'text/html',
'content-length': '114', 'server': 'Apache', 'accept-ranges': 'bytes',
'vary': 'Accept-Encoding', 'content-encoding': 'gzip', 'x-iplb-request-id':
'2A010E0A014961907C271B558D29C44A:D110_200141D000011B000213018600330004:0050_62
 'x-iplb-instance': '31965'}
>>> r.content
b'<!DOCTYPE
html>\n<html>\n<head>\n<title>Waouh</title>\n</head>\n<body>\nCeci est
vraiment une jolie page web.\n</body>\n</html>\n'
>>> r.text
'<!DOCTYPE html>\n<html>\n<head>\n<title>Waouh</title>\n</head>\n<body>\nCeci
est vraiment une jolie page web.\n</body>\n</html>\n'
```